

Spec-Driven Development (SDD)

Objetivo: A especificação como Fonte da Verdade

- Especificações são o núcleo estratégico do projeto, não apenas documentação passiva
- A implementação é gerada, guiada ou validada rigorosamente
- Redução drástica de ambiguidades entre requisitos e implementação básica
- Otimizado para fluxos de trabalho onde LLMS precisam de contexto preciso
- A documentação sofre drift e torna-se obsoleta deixando o código como a única referência
- Sem especificações claras, llms tentam preencher lacunos de requisitos, resultadno em alucinações de código
- A falta de contratos explícitos gera inconsistências e retrabalho massivo durante a integração de sistemas

Nível 1 (Spec-first)

- ➔ A especificação guia a implementação inicial, excelente para prototipagem rápida e exploração com IA

Nível 2 (Spec-anchored)

- ➔ Sincronia constante entre código e spec. O padrão para sistemas corporativos e contratos de api estáveis

Nível 3 (Spec-As-Source)

- ➔ A especificação é a fonte primária. O código é 100% gerado, eliminando o erro humano por design

O modelo Spec-Anchored mantém uma âncora permanentemente entre a especificação e o código, garantindo que ambos evoluam em paridade total durante todo o ciclo de vida do software

- Código e especificação são mantidos em paridade, qualquer mudança em um exige
- Essencial para sistemas de missão crítica onde a previsibilidade é mais importante que a velocidade bruta
- Implementado através de práticas do BDD e contratos de API rigorosos

O Ciclo de Vida Moderno

Specify (Especificar): Definição rigorosa e formal do comportamento esperado do sistema

Plan (Planejar): Estabelecimento da arquitetura, contratos e restrições técnicas

Implement (Implementar): Codificação assistida por IA baseada fielmente na especificação

Validate (Validar): Verificação automática e testes rigorosos contra a especificação original

- de Alta qualidade: Especificações fornecem o contexto perfeito para llms, eliminando ambiguidades
- Restrições claras na spec impedem que a IA invente comportamentos inexistentes
- Paralelismo de Agentes: Múltiplos agentes de IA podem trabalhar em contratos distintos simultaneamente
- Qualidade do código: Resulta em código modular, limpo e 100% aderente aos requisitos de negócio

Perguntas Orientadoras

1. Dados
 - a. Onde as informações falsas são mais compartilhadas no Brasil? Existe algum controle prévio de quais informações podem ser publicadas?
 - b. Como verificamos a veracidade dos dados (notícias e informações do dataset)?
2. Usuário
 - a. Quais são os grupos sociais mais afetados pela desinformação disseminada na internet?
 - b. Como as pessoas geralmente conferem qual informação é verdadeira ou falsa?
 - c. As pessoas deixam de conferir a veracidade da informação pela dificuldade (tempo/trabalho) em ir para outra página checar?
 - d. O quão importante é o pensamento crítico na interpretação de informações na internet?
 - e.
3. Modelo
 - a. Como podemos criar um modelo de IA que não remova o pensamento crítico do usuário?
 - b. Como avaliar a acurácia dos modelos implementados? E como definir quais algoritmos melhor se encaixam no projeto.
 - c.
4. Produção
 - a. Onde podemos implementar a nossa solução para ajudar o máximo de pessoas?

Entregas da Semana 1

Processo Investigativo: Investigação forense de notícias, explorar datasets públicos sobre fake news, criar uma matriz de confiança

Perguntas sugeridas pelo Claude

Dados

1. Quais características textuais (título sensacionalista, ausência de autoria, linguagem emocional) aparecem com maior frequência em notícias falsas verificadas no Brasil?
2. Existe diferença no padrão de propagação de fake news em períodos eleitorais versus períodos comuns nos datasets disponíveis?
3. Os datasets públicos brasileiros de fake news refletem desinformação de todos os espectros políticos de forma equilibrada, ou há viés de coleta?
4. Quanto tempo em média uma notícia falsa leva para ser desmentida por agências de checagem brasileiras — e o desmentido alcança o mesmo público?
5. É possível identificar nos dados quais formatos (texto, imagem, áudio, vídeo) têm maior taxa de compartilhamento sem verificação prévia?

Usuário

1. Existe diferença no comportamento de verificação entre pessoas que consomem notícias por redes sociais versus por portais de notícia diretamente?
2. O usuário percebe diferença entre uma opinião e um fato quando ambos são apresentados no mesmo formato visual?
3. Quando uma pessoa já compartilhou uma notícia falsa e descobre isso depois, qual é a probabilidade de ela tomar alguma ação corretiva?
4. Quais são as motivações emocionais que levam alguém a compartilhar uma informação sem verificar — indignação, pertencimento, urgência?
5. Uma pessoa com maior escolaridade necessariamente verifica mais informações antes de compartilhar, ou o viés de confirmação age independente do nível educacional?

Modelo

1. Como o modelo pode apresentar evidências contraditórias sem induzir o usuário a uma conclusão específica?
2. Qual é o nível mínimo de explicabilidade que o modelo precisa oferecer para que o usuário confie no processo sem confiar cegamente no resultado?
3. Como o modelo deve se comportar diante de informações que estão em disputa legítima entre especialistas — onde não há consenso claro?
4. É possível medir se o uso contínuo da ferramenta aumenta ou diminui a capacidade do usuário de avaliar informações de forma autônoma?
5. Como evitar que o próprio modelo se torne uma fonte de viés ao priorizar determinadas agências de checagem ou fontes consideradas confiáveis?

Produção

1. A solução funciona melhor como ferramenta ativa (o usuário busca verificar) ou passiva (alerta integrado ao fluxo de consumo de conteúdo)?
2. Como garantir que a solução seja acessível para populações com baixa literacia digital, que são frequentemente as mais vulneráveis à desinformação?
3. Quais são os riscos legais e éticos de classificar publicamente uma notícia como falsa sem o respaldo formal de uma agência de checagem reconhecida?
4. Como a solução se mantém atualizada diante da velocidade com que novos formatos e narrativas de desinformação surgem?
5. Existe algum incentivo real para que plataformas como WhatsApp ou Instagram integrem ou permitam o funcionamento da solução dentro de seus ecossistemas?

	DADOS	USUÁRIO	MODELO	PRODUÇÃO
RESPONDER JÁ				
PLANEJAR				
SE SOBRAR TEMPO				
CORTAR SEM DÓ				

1. DADOS

D1 — Quais características distinguem, com maior frequência, conteúdos verdadeiros, falsos e enganosos sobre saúde no contexto brasileiro?

Atividade prática para responder:

- Selecionar datasets brasileiros de fake news.
- Identificar quais possuem conteúdos relacionados à saúde.
- Definir características textuais a serem analisadas: título, tamanho, linguagem emocional, urgência, uso de números, autoria, fonte, citações científicas etc.

- Criar uma análise exploratória.
- Comparar conteúdos verdadeiros × falsos × enganosos.
- Identificar quais características podem ser úteis para um futuro modelo de IA.

Recursos necessários:

- IA: ChatGPT/Codex/Copilot para auxiliar análise e exploração.
- Python.
- Google Colab.
- Pandas.
- Scikit-learn.
- Hugging Face Datasets.
- Jupyter Notebook.
- Datasets brasileiros de fake news.

Responsável: _____

Prazo:

D2 — Os datasets brasileiros disponíveis são representativos o suficiente para desenvolver uma solução de detecção/verificação de desinformação em saúde?

Atividade prática:

- Levantar datasets públicos.
- Registrar origem, período, quantidade, idioma, categorias e critérios de rotulagem.
- Verificar quantos exemplos são relacionados à saúde.
- Identificar desequilíbrio entre classes.
- Identificar possíveis vieses políticos, temporais ou temáticos.
- Avaliar se será necessário construir um dataset próprio.

Recursos:

- Python/Pandas.
- Hugging Face.
- GitHub.
- Google Colab.
- Pesquisa bibliográfica.
- IA para auxiliar classificação e documentação dos datasets.

Responsável: _____

Prazo:

D3 — Quais fontes brasileiras podem ser consideradas referências confiáveis para verificar alegações de saúde?

Atividade prática:

Construir uma hierarquia de fontes, por exemplo:

1. Ministério da Saúde
2. Anvisa
3. Fiocruz
4. SUS
5. BVS
6. PubMed
7. universidades públicas
8. sociedades médicas
9. agências de checagem
10. veículos jornalísticos

Depois definir critérios objetivos para determinar o grau de confiabilidade de cada fonte.

Recursos:

- Pesquisa web.
- Bases científicas.
- Sites institucionais.
- IA para auxiliar organização e comparação.
- Planilha/Notion.

Responsável: _____

Prazo:

D4 — Qual é a disponibilidade de dados científicos e oficiais que poderiam alimentar um sistema de verificação de alegações sobre saúde?

Atividade prática:

- Mapear APIs.
- Identificar bases abertas.
- Verificar possibilidade de download.
- Verificar formatos.
- Verificar frequência de atualização.
- Verificar licença/termos de uso.

- Testar acesso automatizado às fontes.

Recursos:

- APIs.
- Python.
- Requests.
- Postman.
- OpenAPI.
- GitHub.
- Dados.gov.br.
- PubMed.
- Repositório da UnB.
- Portal do Ministério da Saúde.

Responsável: _____

Prazo:

D5 — Quais tipos de conteúdo representam maior desafio para a verificação automatizada: texto, imagem, áudio, vídeo ou conteúdos multimodais?

Atividade prática:

- Mapear exemplos reais.
- Classificar os tipos de conteúdo.
- Avaliar quais podem ser processados com tecnologias gratuitas.
- Comparar complexidade de OCR, transcrição, análise textual e análise multimodal.
- Definir qual formato será suportado pelo MVP.

Recursos:

- Python.
- OCR.
- Whisper.
- Modelos multimodais.
- Google Colab.
- IA generativa.

Responsável: _____

Prazo:

2. USUÁRIO

U1 — Quem é o usuário prioritário da solução e em quais situações ele precisa verificar uma informação de saúde?

Atividade prática:

- Definir possíveis personas.
- Realizar entrevistas/questionários.
- Identificar situações reais de contato com desinformação.
- Mapear jornada: recebe → acredita → compartilha → verifica.
- Selecionar um público prioritário para o MVP.

Recursos:

- Google Forms.
- Google Sheets.
- Notion/Miro.
- IA para análise qualitativa das respostas.

Responsável: _____

Prazo:

U2 — Quais características da interface facilitam ou dificultam a compreensão de uma classificação de desinformação?

Atividade prática:

Criar protótipos comparando:

- A. “FAKE”
- B. “Provavelmente falso — veja as evidências”
- C. Resultado + fontes + explicação
- D. Resultado + nível de confiança + evidências.

Testar qual formato é melhor compreendido pelos usuários.

Recursos:

- Figma.
- Canva.
- Google Forms.

- Testes com usuários.
- IA para criação de protótipos e análise.

Responsável: _____

Prazo:

U3 — O usuário consegue diferenciar uma opinião, uma interpretação e uma alegação factual verificável?

Atividade prática:

- Criar exemplos de frases.
- Aplicar questionário.
- Medir taxa de acerto.
- Identificar confusões.
- Utilizar os resultados para definir o comportamento do sistema.

Recursos:

- Google Forms.
- Planilha.
- IA para gerar exemplos controlados.
- Análise estatística básica.

Responsável: _____

Prazo:

U4 — Quais fatores influenciam a decisão de compartilhar uma informação de saúde sem verificar sua veracidade?

Atividade prática:

Investigar fatores como:

- urgência;
- medo;
- indignação;
- identificação pessoal;
- pertencimento;
- autoridade aparente;
- linguagem emocional;

- confirmação de crenças prévias.

Realizar revisão bibliográfica + questionário/entrevistas.

Recursos:

- Google Scholar.
- PubMed.
- Google Forms.
- IA para organização da literatura.
- Planilhas.

Responsável: _____

Prazo:

U5 — O nível de escolaridade ou conhecimento digital está relacionado ao comportamento de verificação de informações?

Atividade prática:

- Criar questionário.
- Coletar respostas.
- Comparar grupos.
- Evitar interpretar escolaridade como indicador automático de capacidade crítica.
- Avaliar também literacia digital e familiaridade com fontes científicas.

Recursos:

- Google Forms.
- Google Sheets.
- Python.
- Pandas.
- Estatística básica.

Responsável: _____

Prazo:

3. MODELO / IA

M1 — É mais adequado classificar uma notícia como “verdadeira/falsa” ou avaliar a alegação apresentada com base nas evidências disponíveis?

Atividade prática:

- Pesquisar modelos de fact-checking.
- Comparar classificação tradicional com sistemas de claim verification.
- Criar exemplos.
- Definir categorias do produto.

Possíveis categorias:

- ☒ Sustentada
- ☐ Parcialmente sustentada
- ☐ Enganosa
- ☐ Contradita pelas evidências
- ☐ Não foi possível verificar

Recursos:

- Revisão bibliográfica.
- IA.
- Datasets.
- Artigos científicos.

Responsável: _____

Prazo:

M2 — Qual arquitetura de IA apresenta melhor equilíbrio entre precisão, explicabilidade, custo e facilidade de implementação para o MVP?

Atividade prática:

Comparar pelo menos:

1. ML tradicional;
2. modelo de linguagem especializado;
3. LLM;
4. RAG + LLM.

Construir um pequeno experimento ou prova de conceito.

Recursos:

- Python.

- Scikit-learn.
- Hugging Face.
- Ollama.
- LLM.
- Google Colab.
- PostgreSQL/pgvector, se necessário.

Responsável: _____

Prazo:

M3 — Como o sistema deve apresentar evidências para que o usuário consiga compreender por que determinada alegação foi considerada falsa, enganosa ou não verificável?

Atividade prática:

- Criar diferentes modelos de resposta.
- Definir quantidade de evidências.
- Definir como exibir fontes.
- Testar explicações com usuários.
- Criar padrão de resposta.

Recursos:

- Figma.
- LLM.
- Protótipo funcional.
- Testes de usabilidade.

Responsável: _____

Prazo:

M4 — Como o sistema deve responder quando as evidências científicas forem insuficientes, contraditórias ou estiverem em evolução?

Atividade prática:

Criar casos de teste envolvendo:

- ausência de evidências;
- estudos contraditórios;

- evidências antigas;
- consenso científico;
- novas descobertas.

Definir política de **abstenção da IA**.

Recursos:

- Artigos científicos.
- LLM.
- RAG.
- Dataset de testes.
- Testes automatizados.

Responsável: _____

Prazo: Semana 6

M5 — Como reduzir o risco de o próprio sistema reproduzir vieses das fontes, datasets ou modelos de IA utilizados?

Atividade prática:

- Mapear possíveis fontes de viés.
- Comparar diferentes fontes.
- Avaliar distribuição do dataset.
- Criar critérios de seleção das fontes.
- Criar testes de viés.
- Documentar limitações.

Recursos:

- Python.
- Pandas.
- Scikit-learn.
- IA.
- Revisão bibliográfica.
- Dataset.

Responsável: _____

Prazo: Semana 7

4. PRODUTO / PRODUÇÃO

P1 — Qual formato de produto apresenta maior valor para o usuário: ferramenta de consulta ativa, extensão de navegador, chatbot ou sistema integrado ao fluxo de consumo de notícias?

Atividade prática:

- Criar protótipos de 2–3 alternativas.
- Mapear vantagens e limitações.
- Realizar testes rápidos com usuários.
- Definir o formato do MVP.

Recursos:

- Figma.
- React/Vite.
- Protótipo navegável.
- Testes com usuários.
- IA para prototipação.

Responsável: _____

Prazo: Semana 5

P2 — Como tornar a solução compreensível para usuários com diferentes níveis de literacia digital e científica?

Atividade prática:

- Testar linguagem técnica × linguagem simples.
- Avaliar tamanho das respostas.
- Testar ícones, cores e níveis de informação.
- Avaliar acessibilidade.
- Criar diretrizes de linguagem.

Recursos:

- Figma.
- Testes de usabilidade.
- WCAG.
- IA para revisão de linguagem.

Responsável: _____

Prazo: Semana 6

P3 — Quais são os riscos éticos e jurídicos de uma IA afirmar que determinado conteúdo é falso?

Atividade prática:

- Pesquisar legislação brasileira.
- Analisar LGPD quando aplicável.
- Pesquisar responsabilidade por decisões automatizadas.
- Analisar riscos de difamação e danos reputacionais.
- Definir limites de uso.
- Criar disclaimer e política de funcionamento.

Recursos:

- Pesquisa jurídica.
- LGPD.
- Marco Civil da Internet.
- Literatura acadêmica.
- IA para auxiliar levantamento, sem substituir análise jurídica especializada.

Responsável: _____

Prazo: Semana 7

P4 — Como manter automaticamente atualizada a base de evidências utilizada pelo sistema?

Atividade prática:

Projetar pipeline:

Nova fonte



Coleta



Validação



Processamento



Embeddings



Banco de dados



Nova evidência disponível

Definir frequência de atualização e critérios para inclusão/exclusão de documentos.

Recursos:

- Python.
- APIs.
- PostgreSQL.
- pgvector.
- GitHub Actions.
- FastAPI.
- RAG.

Responsável: _____

Prazo: Semana 7

P5 — Quais condições técnicas, institucionais e de governança seriam necessárias para que a solução pudesse ser adotada por uma universidade pública ou organização de saúde?

Atividade prática:

- Identificar usuários institucionais.
- Mapear requisitos de segurança.
- Mapear infraestrutura.
- Identificar requisitos de auditoria.
- Avaliar custos.
- Definir possibilidades de implantação em universidade pública.
- Identificar potenciais parceiros.

Recursos:

- Pesquisa documental.
- Entrevistas.
- Arquitetura de software.
- GitHub.
- Docker.
- Cloud/free tiers, quando disponíveis.

Responsável: _____

Prazo: Semana 8

A pergunta mais estratégica do projeto

Das Guiding Questions de vocês, essa é a mais difícil e mais importante: *"Como podemos criar um modelo de IA que não remove o pensamento crítico do usuário?"*

A resposta provavelmente não é um classificador que diz "FALSO" ou "VERDADEIRO". É algo mais próximo de um assistente que mostra evidências, aponta sinais de alerta, sugere fontes para checagem — e deixa a pessoa decidir. Isso vai orientar toda a arquitetura da solução.

Se quiser, posso ajudar a desenvolver a matriz de confiança, estruturar o portfólio de pesquisa, ou explorar datasets específicos para as próximas semanas.

Read and created memory

Salvei o contexto do challenge. Qualquer coisa que precisar ao longo das 6 semanas — estruturar a matriz de confiança, explorar datasets, pensar na arquitetura da solução, preparar a apresentação — é só chamar.

consegue me ajudar a entender melhor então esse questão do raciocínio lógico, porque não sei se entendi muito bem como podemos ajudar as pessoas a ainda nessa era da IA onde as pessoas estão cada vez mais terceirizando seus pensamentos

Essa é uma das perguntas mais importantes do seu challenge — e também uma das mais filosóficas. Deixa eu te ajudar a construir um raciocínio sólido sobre isso.

O problema real: terceirização cognitiva

Existe um fenômeno que psicólogos e cientistas cognitivos chamam de **cognitive offloading** — descarregar tarefas mentais para ferramentas externas. Isso não é novo: aconteceu com a calculadora, o GPS, o Google. A IA só acelerou drasticamente esse processo.

O problema não é usar ferramentas. É **perder a capacidade de funcionar sem elas**.

Com fake news isso fica perigoso por um motivo específico: verificar informação exige julgamento contextual, não só processamento de dados. Uma IA pode te dizer que uma fonte tem histórico duvidoso. Mas ela não consegue te dizer *por que aquela informação específica, naquele contexto político e emocional, está sendo compartilhada agora* — isso exige raciocínio humano situado.

O que está acontecendo com o pensamento crítico

Três mecanismos estão em jogo simultaneamente:

- 1. Preguiça epistêmica.** Quando uma ferramenta dá uma resposta pronta, o cérebro tende a aceitá-la sem questionar — especialmente se a resposta confirma o que já acreditamos (viés de confirmação). Com IA isso é amplificado porque a resposta vem com aparência de autoridade e confiança.
- 2. Atrofia por desuso.** Habilidades que não são praticadas enfraquecem. Se uma pessoa nunca precisar avaliar uma fonte por conta própria porque sempre delega para uma IA, ela literalmente perde essa capacidade ao longo do tempo.
- 3. Ilusão de competência.** A pessoa acha que sabe verificar informação, mas na verdade só sabe perguntar para a IA. Se a IA errar — e ela erra — o usuário não tem como detectar o erro.

A distinção que resolve a Guiding Question de vocês

A diferença entre uma IA que **substitui** o pensamento e uma que **amplifica** está no design da interação:

IA que substitui	IA que amplifica
"Essa notícia é falsa."	"Encontrei 3 sinais de alerta nessa notícia. Quer entender cada um?"
Dá veredito pronto	Apresenta evidências e pede que o usuário interprete
Remove a dúvida	Instala a dúvida produtiva
Responde	Pergunta

A solução de vocês provavelmente precisa ser desenhada para **criar fricção cognitiva intencional** — fazer o usuário parar, pensar, questionar — em vez de remover essa fricção.

Um exemplo concreto de como isso funciona na prática

Imagina dois designs de solução:

Design A (substitui): Usuário cola uma notícia → IA retorna "Confiabilidade: 23% — PROVÁVEL FAKE NEWS"

Design B (amplifica): Usuário cola uma notícia → IA retorna:

- "A fonte desse conteúdo não tem CNPJ registrado como veículo jornalístico"
- "A mesma história foi publicada em 47 sites diferentes com o mesmo texto, no mesmo dia"
- "Nenhum veículo com histórico de checagem confirmou essa informação"
- "O que você acha disso? Isso muda sua percepção sobre a notícia?"

O Design B entrega as mesmas informações, mas coloca o humano no papel de juiz — não a IA. Isso é exatamente o que a Essential Question do challenge pede.

Como isso conecta com o seu portfólio de pesquisa

Nas semanas 2 e 3 (Investigate), vale a pena pesquisar:

- **Prebunking vs Debunking** — pesquisas mostram que ensinar as pessoas a reconhecer *padrões* de desinformação antes de encontrá-la é muito mais eficaz do que corrigir depois. O projeto [inoculation theory](#) da Cambridge é uma boa referência.
 - **Lateral reading** — técnica usada por fact-checkers profissionais: em vez de ler o artigo em profundidade, abrimos outras abas imediatamente para checar a fonte. É ensinável e escalável.
 - **Alfabetização midiática** como intervenção comprovada.
-

O que isso significa para vocês como equipe

A pergunta que vale colocar no centro do projeto é: **nossa solução, depois de usada por 6 meses, deixa o usuário mais ou menos capaz de pensar criticamente sozinho?**

Se a resposta for "menos", o design precisa mudar — independente de como a tecnologia funciona por baixo.

Isso é o que vai fazer o projeto ser sofisticado de verdade. Qualquer grupo pode fazer um classificador. Poucos conseguem construir algo que treina quem usa.

Guia Prático de Implementação: Spec-Driven Development (SDD)

Diretrizes centrais para a adoção do ecossistema Spec-Driven Development (SDD). O propósito primordial consiste em assegurar que a Inteligência Artificial atue como motor de execução rigoroso das especificações, abstendo-se de tomar decisões arquiteturais autônomas.

1. Organização e Arquitetura de Diretórios

Visando a manutenibilidade e padronização da base de código, adota-se a seguinte estrutura no repositório do projeto (versionado via Git/GitHub):

meu-projeto/

- .cursorrules: Definição rigorosa de contexto, stack técnica e prompts para a IA

docs/

- specs/: Diretório onde habitam todas as especificações e contratos de funcionalidades
 - 00-template-spec.txt
 - 01-exemplo-endpoint-fastapi.txt
- src/: Código-fonte primário da aplicação (ex: rotas FastAPI, modelos de dados)
- tests/: Suíte de testes automatizados (ex: validações em Pytest)
- docker-compose.yml: Configuração de infraestrutura isolada e serviços auxiliares como Redis e Bancos de Dados

2. O Ciclo de Vida do Desenvolvimento (Fluxo SDD)

O ciclo de vida de qualquer nova funcionalidade exige obediência estrita às quatro etapas do fluxo moderno:

Specify (Especificar) — O Desenvolvedor como Arquiteto

- Duplicar o modelo padrão e atribuir uma nomenclatura clara e descritiva
- Formalizar detalhadamente as regras de negócio, esquemas de persistência e contratos de API
- Efetuar o commit da Spec antes de iniciar qualquer codificação manual ou automatizada

Plan (Planejar) — O Agente de IA

- Fornecer a especificação em texto como contexto primário para o agente de IA
- Solicitar um planejamento arquitetural: "Mapeie quais arquivos em src/ serão criados ou adaptados"
- Validar e aprovar o plano técnico caso esteja em paridade com as restrições desejadas

Implement (Implementar) — O Agente de IA

- Orientar a IA a executar a codificação estruturada baseando-se estritamente no plano aprovado
- Garantir que a IA preveja atualizações nos contêineres Docker caso novas bibliotecas sejam adicionadas

Validate (Validar) — Revisão Humana e Verificação Automatizada

- Exigir a criação de testes automatizados em Pytest para cobrir 100% dos critérios de aceitação
- Rodar os testes em ambiente local e conduzir a revisão de código com foco na elegância arquitetural

3. Estrutura do Template de Spec (00-template-spec.txt)

NOME DA FUNCIONALIDADE: [Identificação da Feature]

OBJETIVO:

Síntese clara do problema de negócio que a implementação busca resolver.

REGRAS DE NEGÓCIO:

- Regra 1: Definição dos comportamentos e restrições fundamentais
- Regra 2: Para entidades e modelos de persistência, é mandatório gerar uma chave primária 'id' (evitando usar documentos como CPF como identificador único)

CONTRATOS DE INTERFACE / API:

- Endpoint: POST /api/v1/recurso
- Payload esperado: { "campo": "valor" }
- Retorno de Sucesso: 201 Created
- Retorno de Erro: 400 Bad Request

CRITÉRIOS DE ACEITAÇÃO (Checklist de Validação):

- Validação automática e tratamento rigoroso de entradas inválidas
- Garantia de que os dados gravados no PostgreSQL/MongoDB respeitam a tipagem e o esquema
- A resposta do endpoint satisfaz os parâmetros de latência esperados

4. Princípios Fundamentais do SDD

- A especificação é a Fonte Primária da Verdade no projeto
- Caso ocorram divergências, alterações de arquitetura ou falhas, atualize o arquivo .txt em primeiro lugar, coibindo modificações isoladas no código

Clareza e precisão: elimine instruções genéricas ou ambíguas, especificando restrições e contratos formais de forma explícita